Universidad Nacional Autónoma de México

Facultad de Ingeniería

PRÁCTICA 5

SELECCIÓN DE CARACTERISTICAS

ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

Minería de Datos

Profesor:

Dr. Molero Castillo Guillermo Gilberto

Grupo 1

Alumna:

Monroy Velázquez Alejandra Sarahí

No. Cuenta: 314000417

OBJETIVO

Realizar un análisis de componentes principales (ACP o PCA, Principal Component Analysis) para reducir la cantidad de variables del conjuntos de datos.

DESARROLLO

El conjunto de datos corresponde a estudios clínicos a partir de imágenes digitalizadas de pacientes con cáncer de mama de Wisconsin (WDBC, Wisconsin Diagnostic Breast Cancer). Este conjunto de datos incluye:

Variable	Descripción	Tipo
ID number	Identifica al paciente	Discreto
Diagnosis	Diagnostico (M=maligno, B=benigno)	Booleano
Radius	Media de las distancias del centro y puntos del perímetro	Continuo
Texture	Desviación estándar de la escala de grises	Continuo
Perimeter	Valor del perímetro del cáncer de mama	Continuo
Area	Valor del área del cáncer de mama	Continuo
Smoothness	Variación de la longitud del radio	Continuo
Compactness	Perímetro ^ 2 /Area - 1	Continuo
Concavity	Caída o gravedad de las curvas de nivel	Continuo
Concave points	Número de sectores de contorno cóncavo	Continuo
Symmetry	Simetría de la imagen	Continuo
Fractal dimension	"Aproximación de frontera" - 1	Continuo

Primero comenzamos la importación de bibliotecas correspondientes que nos ayudarán para la realización del código, las cuales son *pandas* para la manipulación y análisis de datos, *numpy* para crear vectores y matrices, *matplotlib* para la generación de gráficas, así como *seaborn* para la visualización de datos. En esta práctica agregamos una biblioteca más, la cual es *sklearn* que nos ayudara para la estandarización de los datos y para el análisis de componentes. Por último, la biblioteca files para subir el archivo *csv*.

Una vez importadas, el *dataframe* se lee y se despliega en pantalla:

```
[4]  import pandas as pd                          # Para la manipulación y análisis de datos
     import numpy as np                           # Para crear vectores y matrices n dimensionales
     import matplotlib.pyplot as plt              # Para la generación de gráficas a partir de los datos
     import seaborn as sns                        # Para la visualización de datos basado en matplotlib
     %matplotlib inline
     from sklearn.preprocessing import StandardScaler
     from sklearn.decomposition import PCA
```

```
from google.colab import files
files.upload()
```

```
Elegir archivos  OriginalWDBC.txt
• OriginalWDBC.txt(text/plain) - 45410 bytes, last modified: 30/9/2021 - 100% done
Saving OriginalWDBC.txt to OriginalWDBC.txt
{'OriginalWDBC.txt': b'Identificador\tDiagnosis\tRadius\tTexture\tPerimeter\tArea\tSmoothness\tCompactr
```

```
[6] BCancer = pd.read_table("OriginalWDBC.txt")
    BCancer
```

	Identificador	Diagnosis	Radius	Texture	Perimeter	Area	Smoothness	Compactness	Concavity	ConcavePoints	Symmetry	FractalDimension
0	P-842302	M	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.30010	0.14710	0.2419	0.07871
1	P-842517	M	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.08690	0.07017	0.1812	0.05667
2	P-84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.19740	0.12790	0.2069	0.05999
3	P-84348301	M	11.42	20.38	77.58	386.1	0.14250	0.28390	0.24140	0.10520	0.2597	0.09744
4	P-84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.19800	0.10430	0.1809	0.05883
...	...	...	...	...	...	...	...	...	...	...	...	...
564	P-926424	M	21.56	22.39	142.00	1479.0	0.11100	0.11590	0.24390	0.13890	0.1726	0.05623
565	P-926682	M	20.13	28.25	131.20	1261.0	0.09780	0.10340	0.14400	0.09791	0.1752	0.05533
566	P-926954	M	16.60	28.08	108.30	858.1	0.08455	0.10230	0.09251	0.05302	0.1590	0.05648
567	P-927241	M	20.60	29.33	140.10	1265.0	0.11780	0.27700	0.35140	0.15200	0.2397	0.07016
568	P-92751	B	7.76	24.54	47.92	181.0	0.05263	0.04362	0.00000	0.00000	0.1587	0.05884

569 rows x 12 columns

Ahora que el *dataframe* está cargado, comenzamos con los pasos vistos en clase:

Paso 1)

En este paso estandarizamos o normalizamos el rango de las variables iniciales, para que cada una de ellas contribuya por igual al análisis. Para ello instanciamos el objeto StandardScaker, después borramos las columnas que no necesitamos, en este caso *Identificador y Diagnosis* los cuales son nominales. Con el método *fit()* calculamos media y desviación estándar de cada variable. Por último, normalizamos los datos mediante el método *trasnsform()* y guardamos en una nueva variable llamada *MNormalizada*.

```
[7] normalizar = StandardScaler()                                          # Se instancia el objeto StandardScaler
    NuevaMatriz = BCancer.drop(columns=['Identificador', 'Diagnosis'])     # Se quitan las variables no necesarias (nominales)
    normalizar.fit(NuevaMatriz)                                            # Se calcula la media y desviación para cada variable
    MNormalizada = normalizar.transform(NuevaMatriz)                       # Se normalizan los datos
```

```
[8] MNormalizada.shape
```

```
(569, 10)
```

```
[9] pd.DataFrame(MNormalizada, columns=NuevaMatriz.columns)
    #MNormalizada
```

	Radius	Texture	Perimeter	Area	Smoothness	Compactness	Concavity	ConcavePoints	Symmetry	FractalDimension
0	1.097064	-2.073335	1.269934	0.984375	1.568466	3.283515	2.652874	2.532475	2.217515	2.255747
1	1.829821	-0.353632	1.685955	1.908708	-0.826962	-0.487072	-0.023846	0.548144	0.001392	-0.868652
2	1.579888	0.456187	1.566503	1.558884	0.942210	1.052926	1.363478	2.037231	0.939685	-0.398008
3	-0.768909	0.253732	-0.592687	-0.764464	3.283553	3.402909	1.915897	1.451707	2.867383	4.910919
4	1.750297	-1.151816	1.776573	1.826229	0.280372	0.539340	1.371011	1.428493	-0.009560	-0.562450
...	...	...	...	...	...	...	...	...	...	...
564	2.110995	0.721473	2.060786	2.343856	1.041842	0.219060	1.947285	2.320965	-0.312589	-0.931027
565	1.704854	2.085134	1.615931	1.723842	0.102458	-0.017833	0.693043	1.263669	-0.217664	-1.058611
566	0.702284	2.045574	0.672676	0.577953	-0.840484	-0.038680	0.046588	0.105777	-0.809117	-0.895587
567	1.838341	2.336457	1.982524	1.735218	1.525767	3.272144	3.296944	2.658866	2.137194	1.043695
568	-1.808401	1.221792	-1.814389	-1.347789	-3.112085	-1.150752	-1.114873	-1.261820	-0.820070	-0.561032

569 rows x 10 columns

Paso 2) y 3)

Una vez que los datos han sido normalizados, calculamos la matriz de covarianzas o correlaciones y calculamos los componentes (eigen-vectores) y la varianza (eigen-valores), y los imprimimos.

```
[10] pca = PCA(n_components=None)          # Se instancia el objeto PCA, pca=PCA(n_components=None), pca=PCA(.85)
     pca.fit(MNormalizada)                 # Se obtiene los componentes
     print(pca.components_)
```

```
[[ 3.63937928e-01  1.54451129e-01  3.76044342e-01  3.64085847e-01
   2.32480530e-01  3.64442059e-01  3.95748488e-01  4.18038400e-01
   2.15237970e-01  7.18374352e-02]
 [-3.13929073e-01 -1.47180910e-01 -2.84657885e-01 -3.04841714e-01
   4.01962323e-01  2.66013147e-01  1.04285969e-01  7.18360466e-03
   3.68300910e-01  5.71767700e-01]
 [-1.24427590e-01  9.51056591e-01 -1.14083595e-01 -1.23377856e-01
  -1.66532470e-01  5.82778620e-02  4.11464835e-02 -6.85538259e-02
   3.67236467e-02  1.13583953e-01]
 [ 2.95588570e-02  8.91608121e-03  1.34580681e-02  1.34426810e-02
  -1.07802034e-01 -1.85700414e-01 -1.66653518e-01 -7.29839511e-02
   8.92998475e-01 -3.49331792e-01]
 [-3.10670238e-02 -2.19922759e-01 -5.94508289e-03 -1.93412233e-02
  -8.43745291e-01  2.40182964e-01  3.12533253e-01 -9.18019959e-03
   1.12888066e-01  2.64878075e-01]
 [-2.64180151e-01 -3.22065675e-02 -2.37819464e-01 -3.31707451e-01
   6.22253741e-02  5.27109684e-03  6.01467157e-01  2.65613396e-01
  -6.19570070e-02 -5.67918995e-01]
 [-4.41883879e-02  2.05574807e-02 -8.33692247e-02  2.61187967e-01
   1.12919772e-02 -8.03804838e-01  3.67136295e-01  1.41313069e-01
   4.79020066e-02  3.45213591e-01]
 [ 8.48340616e-02 -7.12679476e-03  8.92588808e-02  1.44609745e-01
   1.70503132e-01  6.39801435e-02  4.49573310e-01 -8.50918764e-01
   1.64556026e-02 -6.52594660e-02]
 [-4.74425304e-01 -4.21262951e-03 -3.80167210e-01  7.47347358e-01
  -5.84738672e-03  2.18732406e-01 -8.11706695e-02  2.20246512e-02
  -9.06784987e-03 -1.29667490e-01]
 [-6.69071489e-01  2.49782581e-04  7.40490534e-01 -3.23589581e-02
   3.69040560e-03 -5.27527799e-02 -1.03668029e-02 -3.74754732e-03
   1.46694726e-03  7.05734783e-03]]
```

Paso 4)

En este paso decidimos el número de componentes principales, primeramente, calculamos el porcentaje de relevancia, es decir, entre el 75% y 90% de varianza total; si tomamos 4 componentes obtenemos el 93%, por lo que lo correcto será tomar 3 componentes ya que nos da un 88% y este porcentaje si entra dentro del rango requerido.

```
[11] Varianza = pca.explained_variance_ratio_
     print('Proporción de varianza:', Varianza)
     print('Varianza acumulada:', sum(Varianza[0:4]))
     #Con 3 componentes se tiene el 88% de varianza acumulada y con 4 el 93%
```

```
Proporción de varianza: [5.47858799e-01 2.51871359e-01 8.80615179e-02 4.99009435e-02
 3.72539192e-02 1.24141748e-02 8.00853111e-03 3.48897932e-03
 1.11354606e-03 2.82305886e-05]
Varianza acumulada: 0.9376926189556111
```

Luego graficamos la varianza acumulada de los componentes, como observamos en la gráfica, podemos identificar con mayor facilidad el grupo de componentes con mayor varianza.

```
[12] # Se grafica la varianza acumulada en las nuevas dimensiones
     plt.plot(np.cumsum(pca.explained_variance_ratio_))
     plt.xlabel('Número de componentes')
     plt.ylabel('Varianza acumulada')
     plt.grid()
     plt.show()
```

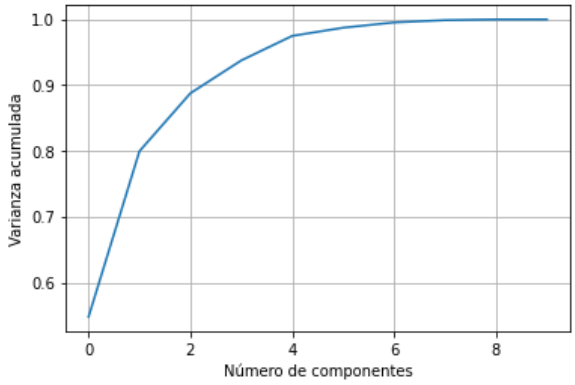

Paso 5)

Como último paso examinamos la proporción de relevancia o las cargas. Se revisan los valores absolutos de los componentes principales seleccionados. Como cuanto mayor sea el valor absoluto, más importante es esa variable en el componente principal, en este caso, identificamos las cargas mayores al 37%:

```
CargasComponentes = pd.DataFrame(abs(pca.components_), columns=NuevaMatriz.columns)
CargasComponentes
```

	Radius	Texture	Perimeter	Area	Smoothness	Compactness	Concavity	ConcavePoints	Symmetry	FractalDimension
0	0.363938	0.154451	0.376044	0.364086	0.232481	0.364442	0.395748	0.418038	0.215238	0.071837
1	0.313929	0.147181	0.284658	0.304842	0.401962	0.266013	0.104286	0.007184	0.368301	0.571768
2	0.124428	0.951057	0.114084	0.123378	0.166532	0.058278	0.041146	0.068554	0.036724	0.113584
3	0.029559	0.008916	0.013458	0.013443	0.107802	0.185700	0.166654	0.072984	0.892998	0.349332
4	0.031067	0.219923	0.005945	0.019341	0.843745	0.240183	0.312533	0.009180	0.112888	0.264878
5	0.264180	0.032207	0.237819	0.331707	0.062225	0.005271	0.601467	0.265613	0.061957	0.567919
6	0.044188	0.020557	0.083369	0.261188	0.011292	0.803805	0.367136	0.141313	0.047902	0.345214
7	0.084834	0.007127	0.089259	0.144610	0.170503	0.063980	0.449573	0.850919	0.016456	0.065259
8	0.474425	0.004213	0.380167	0.747347	0.005847	0.218732	0.081171	0.022025	0.009068	0.129667
9	0.669071	0.000250	0.740491	0.032359	0.003690	0.052753	0.010367	0.003748	0.001467	0.007057

Las variables restantes que no tuvieron cargas mayores al porcentaje esperado se eliminan del *dataframe*, en este caso las variables son *Radius*, *Area*, *Compactness*, *Symmetry* e *Identificador*.

```
[16] DatosCancer = BCancer.drop(columns=['Identificador', 'Radius', 'Area', 'Compactness', 'Symmetry'])
     DatosCancer
```

	Diagnosis	Texture	Perimeter	Smoothness	Concavity	ConcavePoints	FractalDimension
0	M	10.38	122.80	0.11840	0.30010	0.14710	0.07871
1	M	17.77	132.90	0.08474	0.08690	0.07017	0.05667
2	M	21.25	130.00	0.10960	0.19740	0.12790	0.05999
3	M	20.38	77.58	0.14250	0.24140	0.10520	0.09744
4	M	14.34	135.10	0.10030	0.19800	0.10430	0.05883
...	...	...	...	...	...	...	...
564	M	22.39	142.00	0.11100	0.24390	0.13890	0.05623
565	M	28.25	131.20	0.09780	0.14400	0.09791	0.05533
566	M	28.08	108.30	0.08455	0.09251	0.05302	0.05648
567	M	29.33	140.10	0.11780	0.35140	0.15200	0.07016
568	B	24.54	47.92	0.05263	0.00000	0.00000	0.05884

569 rows x 7 columns

CONCLUSIÓN

En esta práctica seguimos trabajando con el análisis de componentes principales, pero ahora con un conjunto de datos diferentes los cuales correspondían a los diagnósticos de cáncer de mama de Wisconsin, en este caso hubieron ciertas diferencias con respecto al de la practica cuatro, aunque el método es el mismo, hay que identificar con que set de datos estamos trabajando y como se conforma, en esta practica tuvimos que eliminar las columnas de *identificador* y *diagnosis* ya que eran innecesarias para nuestro análisis numérico, además al examinar las cargas, también el porcentaje decidido fue diferente, ya que fue menor con el fin de no eliminar la mayoría de variables.